

Yapay Sinir Ağları ve LSTM Modeli ile THYAO Hisse Senedi Kapanış Fiyatı Tahmini

İbrahim Kayar
Yıldız Teknik Üniversitesi - İstatistik

Özet

Bu çalışmada yapay sinir ağlarının temel yapısı, başlıca türleri ve kullanım alanları ele alınmıştır. Yapay sinir ağları; sınıflandırma, regresyon, görüntü işleme, doğal dil işleme ve zaman serisi tahmini gibi birçok alanda kullanılmaktadır. Çalışmanın uygulama bölümünde ise zaman serisi verileri için uygun bir yapay sinir ağı modeli olan LSTM kullanılmıştır. Bu kapsamda Borsa İstanbul'da işlem gören Türk Hava Yolları A.O. (THYAO) hisse senedinin 2016-2025 dönemine ait günlük verileri incelenmiştir. Modelde açılış fiyatı, en yüksek fiyat, en düşük fiyat, kapanış fiyatı ve işlem hacmi değişkenleri kullanılmıştır. Amaç, kesin yatırım tahmini yapmak değil, LSTM yapay sinir ağının finansal bir zaman serisi üzerinde nasıl uygulanabileceğini göstermektir. Elde edilen sonuçlara göre model genel fiyat eğilimini belirli ölçüde takip etmiş, ancak finansal verilerin yüksek oynaklığı nedeniyle tahmin performansı sınırlı kalmıştır.

Anahtar Kelimeler: Yapay Sinir Ağları, LSTM, Zaman Serisi, Hisse Senedi Tahmini, THYAO

1 Giriş

Yapay sinir ağları, insan beynindeki nöronların çalışma mantığından esinlenerek geliştirilen makine öğrenmesi modelleridir. Bu modeller, veriler arasındaki karmaşık ilişkileri öğrenebilme yeteneğine sahiptir. Özellikle büyük veri, yüksek işlem gücü ve gelişmiş yazılım araçlarının yaygınlaşmasıyla birlikte yapay sinir ağları birçok alanda kullanılmaya başlanmıştır.

Yapay sinir ağları; görüntü tanıma, ses işleme, doğal dil işleme, tıbbi teşhis, finansal tahmin, müşteri davranışı analizi ve zaman serisi modelleme gibi farklı alanlarda uygulanmaktadır. Bu modellerin temel avantajı, doğrusal olmayan ilişkileri öğrenebilmesi ve karmaşık veri yapılarında başarılı sonuçlar üretebilmesidir.

Bu çalışmanın temel amacı, yapay sinir ağlarını teorik olarak açıklamak ve bu ağların zaman serisi verileri üzerinde nasıl uygulanabileceğini göstermektir. Uygulama kısmında THYAO hisse senedinin günlük borsa verileri kullanılmış ve LSTM modeliyle kapanış fiyatı tahmini yapılmıştır. Çalışmanın amacı yatırım tavsiyesi üretmek değil, yapay sinir ağlarının uygulamalı kullanımını göstermektir.

2 Yapay Sinir Ağlarının Temel Yapısı

Yapay sinir ağları genel olarak giriş katmanı, gizli katmanlar ve çıktı katmanından oluşur. Giriş katmanı modele verilen bağımsız değişkenleri temsil eder. Gizli katmanlar, verideki ilişkilerin öğrenildiği katmanlardır. Çıktı katmanı ise modelin tahmin sonucunu üretir.

Bir yapay sinir ağında her bağlantının bir ağırlığı vardır. Model eğitim sürecinde bu ağırlıkları güncelleyerek hata miktarını azaltmaya çalışır. Bu süreçte aktivasyon fonksiyonları da önemli rol oynar. Aktivasyon fonksiyonları modele doğrusal olmayan ilişkileri öğrenme yeteneği kazandırır.

Yapay sinir ağlarında temel işlem şu şekilde özetlenebilir:

$$y = f(w_1x_1 + w_2x_2 + \dots + w_nx_n + b) \quad (1)$$

Burada x giriş değişkenlerini, w ağırlıkları, b bias değerini ve f aktivasyon fonksiyonunu ifade eder.

3 Yapay Sinir Ağlarının Türleri

Yapay sinir ağları kullanım amacına ve veri yapısına göre farklı türlere ayrılır. Her yapay sinir ağı türü her problem için uygun değildir. Bu nedenle model seçimi yapılırken veri yapısı, hedef değişken ve problemin amacı dikkate alınmalıdır.

3.1 Perceptron

Perceptron, en temel yapay sinir ağı modelidir. Tek katmanlı bir yapıya sahiptir ve genellikle basit sınıflandırma problemlerinde kullanılır. Doğrusal olarak ayrılabilen verilerde başarılıdır. Ancak karmaşık ve doğrusal olmayan problemlerde yetersiz kalır.

Kullanım alanları:

- Basit sınıflandırma problemleri
- Temel yapay sinir ağı mantığını açıklama
- Doğrusal ayrılabilir veri kümeleri

3.2 Çok Katmanlı Algılayıcı

Çok Katmanlı Algılayıcı, yani MLP, birden fazla gizli katmana sahip ileri beslemeli yapay sinir ağıdır. MLP modelleri hem sınıflandırma hem de regresyon problemlerinde kullanılabilir. Tablo yapısındaki veriler için oldukça yaygındır.

Kullanım alanları:

- Müşteri kaybı tahmini
- Kredi riski tahmini
- Hastalık sınıflandırması
- Satış veya fiyat tahmini

3.3 İleri Beslemeli Yapay Sinir Ağları

İleri beslemeli yapay sinir ağlarında veri yalnızca giriş katmanından çıktı katmanına doğru ilerler. Geriye doğru bağlantı yoktur. Bu ağlar özellikle bağımsız gözlemlerden oluşan veri setlerinde kullanılır.

Kullanım alanları:

- Sınıflandırma
- Regresyon
- Genel tahmin problemleri

3.4 Evrişimli Sinir Ağları

Evrişimli Sinir Ağları, yani CNN, özellikle görüntü verileri için geliştirilmiştir. Görsellerdeki kenar, şekil, renk ve desen gibi özellikleri otomatik olarak öğrenebilir. CNN modelleri filtreler yardımıyla görüntülerden özellik çıkarır.

Kullanım alanları:

- Görüntü sınıflandırma
- Yüz tanıma
- Tıbbi görüntü analizi
- Nesne tespiti

3.5 Tekrarlayan Sinir Ağları

Tekrarlayan Sinir Ağları, yani RNN, sıralı veriler için geliştirilmiştir. Bu ağlarda geçmiş gözlemlerin bilgisi sonraki adımlara aktarılabilir. Ancak standart RNN modelleri uzun dönemli bağımlılıkları öğrenmede zorlanabilir.

Kullanım alanları:

- Zaman serileri
- Metin verileri
- Ses verileri
- Sıralı gözlemler

3.6 LSTM

LSTM, RNN modellerinin geliştirilmiş bir türüdür. Uzun dönemli bağımlılıkları öğrenmek için kapı mekanizmalarına sahiptir. Bu nedenle zaman serisi tahmini, doğal dil işleme ve finansal veri analizi gibi alanlarda yaygın olarak kullanılır.

LSTM modelinde temel olarak üç kapı bulunur:

- **Unutma kapısı:** Geçmiş bilgilerin ne kadarının unutulacağını belirler.
- **Giriş kapısı:** Yeni bilginin ne kadarının modele ekleneceğini belirler.
- **Çıkış kapısı:** Hücre durumundan hangi bilginin çıktı olarak verileceğini belirler.

Kullanım alanları:

- Hisse senedi fiyat tahmini
- Döviz kuru tahmini
- Elektrik tüketimi tahmini
- Sıcaklık tahmini
- Metin ve konuşma işleme

3.7 GRU

GRU, LSTM'e benzeyen ancak daha sade bir yapıya sahip olan tekrarlayan sinir ağı türüdür. LSTM'e göre daha az parametre içerir ve bazı durumlarda daha hızlı çalışır.

Kullanım alanları:

- Zaman serisi tahmini

- Metin sınıflandırma
- Daha hızlı modelleme gerektiren sıralı veri problemleri

3.8 Autoencoder

Autoencoder modelleri, veriyi daha düşük boyutlu bir temsile indirgemeyi öğrenen yapay sinir ağlarıdır. Genellikle boyut indirgeme, gürültü giderme ve anomali tespiti için kullanılır.

Kullanım alanları:

- Anomali tespiti
- Veri sıkıştırma
- Gürültü giderme
- Boyut indirgeme

3.9 GAN

GAN, yani Generative Adversarial Network, iki farklı ağın birbiriyle rekabet etmesiyle çalışır. Bir ağ yeni veri üretirken, diğer ağ bu verinin gerçek mi yapay mı olduğunu ayırt etmeye çalışır.

Kullanım alanları:

- Görüntü üretimi
- Yapay veri oluşturma
- Görüntü iyileştirme
- Stil transferi

3.10 Transformer Ağları

Transformer modelleri özellikle doğal dil işleme alanında büyük başarı sağlamıştır. Dikkat mekanizması sayesinde verideki önemli ilişkileri öğrenebilir. Günümüzde büyük dil modellerinin temelinde transformer mimarisi bulunmaktadır.

Kullanım alanları:

- Metin üretimi
- Makine çevirisi
- Özetleme

- Soru-cevap sistemleri
- Büyük dil modelleri

4 Yapay Sinir Ağı Türlerinin Karşılaştırılması

YSA Türü	Uygun Veri Tipi	Kullanım Alanı
Perceptron	Basit doğrusal veri	Temel sınıflandırma
MLP	Tablo verisi	Regresyon ve sınıflandırma
CNN	Görüntü verisi	Görüntü işleme, nesne tanıma
RNN	Sıralı veri	Zaman serisi, metin verisi
LSTM	Uzun dönem bağımlılık içeren sıralı veri	Finansal tahmin, zaman serisi
GRU	Sıralı veri	Hızlı zaman serisi modelleme
Autoencoder	Yüksek boyutlu veri	Anomali tespiti, boyut indirgeme
GAN	Görsel ve üretim odaklı veri	Yapay veri ve görüntü üretimi
Transformer	Metin ve sıralı veri	Doğal dil işleme, büyük dil modelleri

Tablo 1: Yapay sinir ağı türlerinin karşılaştırılması

5 Bu Çalışmada Neden LSTM Kullanıldı?

Bu çalışmada kullanılan veri, günlük hisse senedi fiyatlarından oluşmaktadır. Hisse senedi verileri zaman sırasına bağlıdır. Yani bugünkü fiyat, geçmiş günlerdeki fiyat hareketlerinden etkilenebilir. Bu nedenle veri yapısı sıradan bir tablo verisinden farklıdır.

Bu tür verilerde gözlemlerin sırası önemlidir. Bu yüzden klasik ileri beslemeli ağlar veya MLP modelleri yerine zaman bağımlılığını dikkate alabilen modeller tercih edilmelidir. RNN modelleri sıralı veriler için uygun olsa da uzun dönemli bağımlılıkları öğrenmede yetersiz kalabilir. LSTM ise bu sorunu azaltmak için geliştirilmiştir.

Bu nedenle THYAO kapanış fiyatı tahmini için LSTM modeli tercih edilmiştir. Model, geçmiş 60 güne ait fiyat ve işlem hacmi bilgilerini kullanarak bir sonraki günün kapanış fiyatını tahmin etmeye çalışmıştır.

6 Veri Seti

Çalışmada Türk Hava Yolları A.O. hisse senedine ait günlük borsa verileri kullanılmıştır. Veriler Python programlama dili ve `yfinance` kütüphanesi aracılığıyla Yahoo Finance veri tabanından elde edilmiştir. Veri seti 04.01.2016 ile 31.12.2025 tarihleri arasındaki işlem günlerini kapsamaktadır.


Kullanılan değişkenler Tablo 2’de verilmiştir.

Değişken	Açıklama
Open	Günlük açılış fiyatı
High	Gün içindeki en yüksek fiyat
Low	Gün içindeki en düşük fiyat
Close	Günlük kapanış fiyatı
Volume	Günlük işlem hacmi

Tablo 2: Veri setinde kullanılan değişkenler

Veri seti ilk olarak incelenmiş, eksik değer kontrolü yapılmış ve işlem hacmi sıfır olan günler analiz dışında bırakılmıştır. Temizleme işleminden sonra toplam 2504 gözlem kullanılmıştır.


Aşağıda THYAO kapanış fiyatının yıllara göre değişimi gösterilmiştir.



Şekil 1: THYAO kapanış fiyatı grafiği

Grafik incelendiğinde THYAO kapanış fiyatının özellikle 2022 sonrasında belirgin biçimde yükseldiği görülmektedir. Bu durum veri setinin trend ve oynaklık içerdiğini göstermektedir.

İşlem hacmine ait grafik aşağıda verilmiştir.



Şekil 2: THYAO işlem hacmi grafiği

İşlem hacmi grafiğinde bazı dönemlerde ani yükselişler görülmektedir. Bu durum yatırımcı ilgisi, piyasa haberleri veya genel ekonomik gelişmelerle ilişkili olabilir.

7 Veri Ön İşleme

Model kurulmadan önce veri seti ön işleme aşamalarından geçirilmiştir. Öncelikle tarih değişkeni düzenlenmiş, ardından eksik değer ve sıfır işlem hacmi kontrolleri yapılmıştır. Daha sonra modelde kullanılacak değişkenler seçilmiştir.

Modelde kullanılan girdi değişkenleri şunlardır:

- Open
- High
- Low
- Close
- Volume

Hedef değişken ise bir sonraki günün kapanış fiyatıdır. Bu nedenle model, geçmiş fiyat ve hacim bilgilerini kullanarak gelecekteki kapanış fiyatını tahmin etmeye çalışmıştır.

Yapay sinir ağları farklı ölçeklerdeki değişkenlerden etkilenebildiği için tüm değişkenler Min-Max ölçeklendirme yöntemiyle 0 ile 1 aralığına dönüştürülmüştür. Ayrıca zaman serisi yapısı korunmuş ve veri seti rastgele karıştırılmamıştır. İlk yüzde 80'lik kısım eğitim, son yüzde 20'lik kısım test verisi olarak ayrılmıştır.

LSTM modeli için 60 günlük zaman penceresi oluşturulmuştur. Buna göre model, geçmiş 60 güne ait beş değişkeni kullanarak 61. günün kapanış fiyatını tahmin etmektedir.


8 Model Yapısı

Çalışmada çok değişkenli bir LSTM modeli kurulmuştur. Model mimarisi aşağıdaki gibidir:

- Birinci LSTM katmanı: 64 birim
- Dropout katmanı: 0.20
- İkinci LSTM katmanı: 32 birim
- Dropout katmanı: 0.20
- Dense katmanı: 16 birim
- Çıktı katmanı: 1 birim

Dropout katmanları, modelin eğitim verisine aşırı uyum sağlamasını azaltmak için kullanılmıştır. Modelin kayıp fonksiyonu olarak Ortalama Kare Hata, optimizasyon algoritması olarak ise Adam algoritması tercih edilmiştir. Model 50 epoch boyunca eğitilmiştir.

Modelin eğitim ve test kayıp grafiği aşağıda verilmiştir.



Şekil 3: LSTM modeli eğitim ve test kayıp grafiği

Kayıp grafiği incelendiğinde modelin eğitim sürecinde hata değerlerini azalttığı görülmektedir. Test kaybındaki dalgalanmalar finansal zaman serilerinin oynak yapısıyla ilişkilendirilebilir.

9 Bulgular

Modelin test verisi üzerindeki performansı MAE, MSE, RMSE ve R-kare ölçütleri ile değerlendirilmiştir.


Performans Ölçütü	Değer
MAE	15.36
MSE	289.27
RMSE	17.01
R-kare	0.138

Tablo 3: LSTM modelinin test verisi üzerindeki performans sonuçları

MAE değerinin 15.36 olması, modelin tahminlerinin gerçek kapanış fiyatlarından ortalama yaklaşık 15.36 TL saptığını göstermektedir. RMSE değerinin 17.01 olması, daha büyük tahmin hatalarının da bulunduğunu göstermektedir. R-kare değerinin 0.138 olması ise modelin test dönemindeki fiyat değişimlerini sınırlı düzeyde açıklayabildiğini göstermektedir.

Bu sonuç, çalışmanın başarısız olduğu anlamına gelmemektedir. Çünkü bu çalışmanın temel amacı en yüksek tahmin doğruluğunu elde etmek değil, LSTM yapay sinir ağının bir zaman serisi problemi üzerinde nasıl uygulanabileceğini göstermektir. Finansal zaman serileri yüksek oynaklık içerdiğinden ve hisse fiyatları yalnızca geçmiş fiyat ve işlem hacmi bilgileriyle açıklanamadığından, modelin sınırlı performans göstermesi beklenebilir bir durumdur.

Gerçek ve tahmin edilen kapanış fiyatları aşağıdaki grafikte karşılaştırılmıştır.



Şekil 4: Gerçek ve tahmin edilen THYAO kapanış fiyatları

Grafik incelendiğinde modelin genel fiyat eğilimini belirli ölçüde takip ettiği, ancak ani yükseliş ve düşüş dönemlerinde gerçek fiyatları yakalamakta zorlandığı görülmektedir. Tahmin çizgisinin daha yumuşak olması, LSTM modelinin geçmiş gözlemlerden öğrendiği genel örüntüye göre tahmin üretmesiyle ilişkilidir.

10 Sonuç

Bu çalışmada yapay sinir ağlarının temel yapısı, başlıca türleri ve kullanım alanları açıklanmıştır. Yapay sinir ağlarının veri yapısına göre farklı türlere ayrıldığı görülmüştür. Tablo verilerinde MLP, görüntü verilerinde CNN, sıralı verilerde RNN, LSTM ve GRU, doğal dil işleme problemlerinde ise Transformer mimarileri öne çıkmaktadır.

Uygulama bölümünde, zaman serisi yapısına sahip THYAO hisse senedi verileri üzerinde LSTM modeli kullanılmıştır. Modelde Open, High, Low, Close ve Volume değişkenleri kullanılmış, geçmiş 60 günlük veri ile bir sonraki günün kapanış fiyatı tahmin edilmeye çalışılmıştır.

Elde edilen sonuçlara göre LSTM modeli genel fiyat eğilimini belirli ölçüde takip edebilmiş, ancak ani fiyat hareketlerini yakalamakta zorlanmıştır. R-kare değerinin düşük çıkması, modelin açıklayıcılığının sınırlı olduğunu göstermektedir. Bunun temel nedenlerinden biri, hisse senedi fiyatlarının yalnızca geçmiş fiyat ve işlem hacmi verileriyle değil; makroekonomik göstergeler, şirket haberleri, döviz kuru, faiz oranları, petrol fiyatları ve yatırımcı beklentileri gibi birçok dış faktörle belirlenmesidir.

Bu nedenle çalışmanın sonuçları kesin yatırım tahmini olarak değerlendirilmemelidir. Çalışmanın temel katkısı, LSTM yapay sinir ağının finansal bir zaman serisi üzerinde nasıl uygulanabileceğini göstermesidir. Veri toplama, ön işleme, ölçeklendirme, zaman penceresi oluşturma, model eğitimi ve tahmin sonuçlarının değerlendirilmesi adımları uygulamalı olarak gösterilmiştir.

Gelecek çalışmalarda model performansını artırmak için BIST100 endeksi, döviz kuru, faiz oranı, petrol fiyatı ve haber duyarlılığı gibi ek değişkenler modele dahil edilebilir. Ayrıca LSTM modeli; GRU, ARIMA, MLP veya basit referans modellerle karşılaştırılarak daha kapsamlı bir değerlendirme yapılabilir.

11 Kaynakça

Kaynaklar

- [1] McCulloch, W. S. ve Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, 5, 115-133.
- [2] Rumelhart, D. E., Hinton, G. E. ve Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323, 533-536.
- [3] Hochreiter, S. ve Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780.
- [4] LeCun, Y., Bengio, Y. ve Hinton, G. (2015). Deep learning. *Nature*, 521, 436-444.
- [5] Goodfellow, I., Bengio, Y. ve Courville, A. (2016). *Deep Learning*. MIT Press.
- [6] Yahoo Finance. (2026). THYAO.IS Historical Data. <https://finance.yahoo.com/quote/THYAO.IS/history/>
- [7] TensorFlow Documentation. (2026). Keras LSTM Layer Documentation. https://www.tensorflow.org/api_docs/python/tf/keras/layers/LSTM