

LSTM Yapay Sinir Ağı ile THYAO Hisse Senedi Kapanış Fiyatı Tahmini

İbrahim Kayar

Yıldız Teknik Üniversitesi- İstatistik

2026

Özet

Bu çalışmada, Borsa İstanbul'da işlem gören Türk Hava Yolları A.O. (THYAO) hisse senedinin kapanış fiyatı, Uzun Kısa Süreli Bellek (Long Short-Term Memory, LSTM) yapay sinir ağı modeli kullanılarak tahmin edilmiştir. Çalışmada 2016-2025 dönemine ait günlük hisse senedi verileri kullanılmıştır. Modelde açılış fiyatı, en yüksek fiyat, en düşük fiyat, kapanış fiyatı ve işlem hacmi değişkenleri girdi olarak alınmış, hedef değişken olarak ise bir sonraki günün kapanış fiyatı belirlenmiştir. Elde edilen sonuçlara göre model genel fiyat eğilimini takip edebilmiş, ancak yüksek oynaklık dönemlerinde tahmin hataları artmıştır. Model performansı MAE, MSE, RMSE ve R-kare değerleri ile değerlendirilmiştir.

Anahtar Kelimeler: Yapay Sinir Ağları, LSTM, Zaman Serisi, Hisse Senedi Tahmini, THYAO

1 Giriş

Finansal zaman serilerinin tahmini, ekonomi, finans ve veri bilimi alanlarında önemli bir araştırma konusudur. Hisse senedi fiyatları; ekonomik gelişmeler, şirket haberleri, yatırımcı beklentileri, faiz oranları ve küresel piyasa koşulları gibi birçok faktörden etkilenmektedir. Bu nedenle hisse senedi fiyatlarının tahmin edilmesi doğrusal olmayan ve karmaşık bir problem olarak değerlendirilmektedir.

Geleneksel istatistiksel yöntemler zaman serisi tahmininde yaygın olarak kullanılsa da, son yıllarda yapay sinir ağları finansal verilerdeki karmaşık örüntüleri öğrenebilme kapasiteleri nedeniyle daha fazla tercih edilmeye başlanmıştır. Özellikle LSTM ağları, geçmiş bilgileri hafızada tutabilme yetenekleri sayesinde zaman serisi verileri için uygun bir model yapısı sunmaktadır.

Bu çalışmanın amacı, THYAO hisse senedine ait geçmiş fiyat ve işlem hacmi verilerini kullanarak bir sonraki günün kapanış fiyatını LSTM modeli ile tahmin etmektir.

2 Yapay Sinir Ağları

Yapay sinir ağları, insan beynindeki sinir hücrelerinin çalışma mantığından esinlenen makine öğrenmesi modelleridir. Bir yapay sinir ağı genel olarak giriş katmanı, gizli katmanlar ve çıktı katmanından oluşur. Giriş katmanında modele verilen değişkenler yer alırken, gizli katmanlarda bu değişkenler arasındaki ilişkiler öğrenilir. Çıktı katmanı ise modelin tahmin sonucunu üretir.

Yapay sinir ağlarında her bağlantının bir ağırlığı vardır. Eğitim sürecinde model, tahmin hatasını azaltmak için bu ağırlıkları günceller. Bu sayede model, veri setindeki örüntüleri öğrenerek yeni gözlemler için tahmin yapabilir.

3 LSTM Modeli

LSTM, tekrarlayan sinir ağlarının özel bir türüdür. Standart tekrarlayan sinir ağları uzun dönemli bağımlılıkları öğrenmede zorlanabilir. LSTM modeli ise hücre durumu ve kapı mekanizmaları sayesinde geçmiş bilgileri daha uzun süre saklayabilir. Bu nedenle zaman serisi, doğal dil işleme ve finansal veri tahmini gibi alanlarda yaygın olarak kullanılmaktadır.

LSTM yapısında temel olarak üç kapı mekanizması bulunur:

- **Unutma kapısı:** Geçmiş bilgilerin ne kadarının unutulacağını belirler.
- **Giriş kapısı:** Yeni bilginin ne kadarının hücre durumuna ekleneceğini belirler.
- **Çıkış kapısı:** Hücre durumundan hangi bilginin çıktı olarak verileceğini belirler.

Bu yapı sayesinde LSTM modeli, geçmiş dönemlerdeki fiyat hareketlerini dikkate alarak gelecekteki fiyat hareketleri hakkında tahmin üretebilir.

4 Veri Seti


Çalışmada Türk Hava Yolları A.O. hisse senedine ait günlük borsa verileri kullanılmıştır. Veriler Python programlama dili aracılığıyla `yfinance` kütüphanesi kullanılarak Yahoo Finance veri tabanından elde edilmiştir. Veri seti 04.01.2016 ile 31.12.2025 tarihleri arasındaki işlem günlerini kapsamaktadır.

Veri setinde toplam 2504 gözlem bulunmaktadır. Kullanılan değişkenler şunlardır:

Değişken	Açıklama
Open	Günlük açılış fiyatı
High	Gün içindeki en yüksek fiyat
Low	Gün içindeki en düşük fiyat
Close	Günlük kapanış fiyatı
Volume	Günlük işlem hacmi


Tablo 1: Veri setinde kullanılan değişkenler

Aşağıdaki Şekil 1’de THYAO hisse senedinin 2016-2025 dönemine ait kapanış fiyatı grafiği verilmiştir. Grafik incelendiğinde özellikle 2022 sonrasında kapanış fiyatında belirgin bir yükseliş trendi olduğu görülmektedir.



Şekil 1: THYAO kapanış fiyatı grafiği

Şekil 2’de ise aynı döneme ait işlem hacmi grafiği yer almaktadır. İşlem hacminde bazı dönemlerde ani artışlar olduğu görülmektedir. Bu durum, piyasadaki yatırımcı ilgisi veya haber akışı gibi dış faktörlerle ilişkili olabilir.



Şekil 2: THYAO işlem hacmi grafiği

İlk veri çekme aşamasında işlem hacmi sıfır olan 40 gözlem tespit edilmiştir. Bu gözlemler, işlem gerçekleşmeyen günleri temsil ettiği için analiz dışında bırakılmıştır. Temizleme işleminden sonra veri setinde 2504 gözlem kalmıştır.

Zaman serisi verilerinde gözlemlerin sırası önemli olduğu için veri seti rastgele karıştırılmamıştır. Veri setinin ilk yüzde 80’lik kısmı eğitim verisi, son yüzde 20’lik kısmı ise test verisi olarak ayrılmıştır.

Modelde kullanılan değişkenlerin ölçekleri birbirinden farklıdır. Örneğin fiyat değişkenleri yüzler seviyesindeyken işlem hacmi milyonlar seviyesindedir. Bu nedenle tüm değişkenler Min-Max ölçeklendirme yöntemi ile 0 ile 1 aralığına dönüştürülmüştür.

LSTM modelinin zaman bağımlılığını öğrenebilmesi için 60 günlük zaman penceresi oluşturulmuştur. Buna göre model, geçmiş 60 güne ait Open, High, Low, Close ve Volume değerlerini kullanarak bir sonraki günün kapanış fiyatını tahmin etmektedir.

5 Model Yapısı


Çalışmada çok değişkenli bir LSTM modeli kurulmuştur. Modelde beş farklı değişken girdi olarak kullanılmıştır. Model mimarisi aşağıdaki gibidir:

- Birinci LSTM katmanı: 64 birim
- Dropout katmanı: 0.20

- İkinci LSTM katmanı: 32 birim
- Dropout katmanı: 0.20
- Dense katmanı: 16 birim
- Çıktı katmanı: 1 birim

Modelin kayıp fonksiyonu olarak Ortalama Kare Hata (Mean Squared Error, MSE), optimizasyon algoritması olarak ise Adam algoritması kullanılmıştır. Model 50 epoch boyunca eğitilmiştir.

Modelin eğitim ve test kaybı Şekil 3'te gösterilmiştir. Eğitim kaybının düşük seviyelerde seyretmesi modelin eğitim verisini öğrendiğini göstermektedir. Test kaybındaki dalgalanmalar ise test dönemindeki fiyat hareketlerinin oynak yapısından kaynaklanabilir.



Şekil 3: LSTM modeli eğitim ve test kayıp grafiği

6 Bulgular


Modelin test verisi üzerindeki performansı aşağıdaki metrikler ile değerlendirilmiştir:

Performans Ölçütü	Değer
MAE	15.36
MSE	289.27
RMSE	17.01
R-kare	0.138

Tablo 2: LSTM modelinin test verisi üzerindeki performans sonuçları

MAE değerinin 15.36 olması, modelin tahminlerinin gerçek kapanış fiyatlarından ortalama yaklaşık 15.36 TL saptığını göstermektedir. RMSE değerinin 17.01 olması ise büyük hataların model performansını etkilediğini göstermektedir. R-kare değerinin 0.138 olması, modelin test dönemindeki fiyat değişimlerini sınırlı düzeyde açıklayabildiğini göstermektedir.

Şekil 4'te gerçek kapanış fiyatları ile LSTM modeli tarafından tahmin edilen kapanış fiyatları karşılaştırılmıştır.



Şekil 4: Gerçek ve tahmin edilen THYAO kapanış fiyatları

Grafik incelendiğinde, modelin genel fiyat eğilimini takip ettiği görülmektedir. Ancak tahmin edilen değerlerin birçok dönemde gerçek fiyatların altında kaldığı dikkat çekmektedir. Özellikle ani yükseliş ve düşüş dönemlerinde modelin gecikmeli tepki verdiği görülmektedir.

7 Grafiklerin Yorumlanması

Kapanış fiyatı grafiği incelendiğinde THYAO hisse fiyatının 2016-2021 döneminde daha düşük ve yatay bir seyir izlediği, 2022 sonrasında ise belirgin bir yükseliş trendine girdiği görülmektedir. Bu durum, veri setinin doğrusal olmayan ve dalgalı bir yapıya sahip olduğunu göstermektedir.

İşlem hacmi grafiğinde ise bazı dönemlerde yüksek hacim sıçramaları olduğu görülmektedir. Bu sıçramalar, piyasadaki ani haberler, yatırımcı ilgisi veya genel piyasa hareketleriyle ilişkili olabilir.

Gerçek ve tahmin edilen kapanış fiyatları karşılaştırıldığında, LSTM modelinin genel fiyat eğilimini takip ettiği görülmektedir. Ancak modelin tahmin değerleri çoğu dönemde

gerçek fiyatların altında kalmıştır. Özellikle ani yükseliş ve düşüş dönemlerinde modelin gecikmeli tepki verdiği gözlemlenmiştir. Bu durum, finansal zaman serilerinin yüksek oynaklık içermesi ve yalnızca geçmiş fiyat-hacim verileriyle tam olarak açıklanamamasıyla ilişkilendirilebilir.

8 Sonuç

Bu çalışmada, THYAO hisse senedinin günlük kapanış fiyatı LSTM yapay sinir ağı modeli ile tahmin edilmiştir. Modelde Open, High, Low, Close ve Volume değişkenleri kullanılmış, geçmiş 60 günlük veri ile bir sonraki günün kapanış fiyatı tahmin edilmeye çalışılmıştır.

Elde edilen sonuçlara göre LSTM modeli genel fiyat hareketlerini takip edebilmiş, ancak yüksek oynaklık dönemlerinde tahmin performansı sınırlı kalmıştır. R-kare değerinin düşük olması, modelin test verisindeki değişkenliği yeterince açıklayamadığını göstermektedir. Bununla birlikte MAE ve RMSE değerleri, modelin belirli düzeyde tahmin başarısı sağladığını göstermektedir.

Finansal piyasalarda fiyat hareketleri yalnızca geçmiş fiyatlara bağlı değildir. Makro-ekonomik göstergeler, şirket haberleri, faiz oranları, döviz kuru, petrol fiyatları ve yatırımcı beklentileri de hisse fiyatları üzerinde etkili olabilir. Bu nedenle ilerleyen çalışmalarda modele döviz kuru, BIST100 endeksi, faiz oranı veya haber duyarlılığı gibi ek değişkenlerin dahil edilmesi model performansını artırabilir.

9 Kaynakça

Kaynaklar

- [1] Hochreiter, S. ve Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780.
- [2] Goodfellow, I., Bengio, Y. ve Courville, A. (2016). *Deep Learning*. MIT Press.
- [3] LeCun, Y., Bengio, Y. ve Hinton, G. (2015). Deep learning. *Nature*, 521, 436-444.
- [4] Yahoo Finance. (2026). THYAO.IS Historical Data. <https://finance.yahoo.com/quote/THYAO.IS/history/>
- [5] TensorFlow Documentation. (2026). Keras LSTM Layer Documentation. https://www.tensorflow.org/api_docs/python/tf/keras/layers/LSTM