

Yapay Sinir Ağları ile THYAO Hisse Senedi Kapanış Fiyatı Tahmini: LSTM Tabanlı Bir Uygulama

İbrahim Kayar

Yapay Sinir Ağları Projesi

2026

Özet

Bu çalışmada yapay sinir ağları kavramı teorik olarak incelenmiş ve zaman serisi tahmininde yaygın olarak kullanılan Uzun-Kısa Süreli Bellek Ağı (Long Short-Term Memory, LSTM) modeli THYAO hisse senedi verisi üzerinde uygulanmıştır. Kullanılan veri seti 2023–2025 dönemine ait günlük açılış, en yüksek, en düşük, kapanış fiyatı ve işlem hacmi değişkenlerinden oluşmaktadır. Model performansını artırmak amacıyla gecikmeli kapanış fiyatları, hareketli ortalamalar ve günlük getiri değişkeni oluşturulmuştur. Veri seti zaman serisi yapısına uygun şekilde eğitim ve test setlerine ayrılmış, model geçmiş 30 günlük gözlem penceresini kullanarak bir sonraki günün kapanış fiyatını tahmin edecek biçimde tasarlanmıştır. Model performansı RMSE, MAE ve R^2 metrikleri ile değerlendirilmiştir. Elde edilen sonuçlara göre LSTM modeli test verisindeki değişimin yaklaşık %84.6'sını açıklamış ve genel fiyat trendini başarılı şekilde takip etmiştir.

Anahtar Kelimeler: Yapay Sinir Ağları, LSTM, Zaman Serisi, Hisse Senedi Tahmini, THYAO, Derin Öğrenme

İçindekiler

1 Giriş	4
2 Yapay Sinir Ağları	4
2.1 Yapay Sinir Ağlarının Temel Mantığı	4
2.2 Aktivasyon Fonksiyonları	5
3 Yapay Sinir Ağları Literatür Taraması	5
4 Yapay Sinir Ağı Türleri	6
5 LSTM Mimarisi	6
5.1 LSTM'nin Tercih Edilme Nedeni	6
5.2 LSTM Matematiksel Yapısı	7
6 Veri Seti	7
7 Veri Ön İşleme ve Özellik Mühendisliği	8
7.1 Veri Temizleme	8
7.2 Lag Değişkenleri	9
7.3 Hareketli Ortalamalar	9
7.4 Getiri Değişkeni	9
7.5 Normalizasyon	10
8 Keşifsel Veri Analizi	10
8.1 Korelasyon Matrisi	10
9 Model Tasarımı	11
9.1 Zaman Penceresi Yaklaşımı	11
9.2 Eğitim ve Test Ayrımı	11
9.3 Model Mimarisi	12
9.4 Early Stopping Kullanımı	12
10 Model Eğitimi	13
11 Model Performans Değerlendirmesi	13
11.1 RMSE	13
11.2 MAE	13
11.3 R^2	14
12 Tahmin Sonuçları	14

13 Hata Analizi	15
13.1 Residual Error Grafiđi	15
13.2 Residual Distribution Grafiđi	16
14 Bulguların Genel Deđerlendirilmesi	16
15 Çalışmanın Sınırlılıkları	17
16 Gelecek Çalışmalar	18
17 Sonuç	18

1 Giriş

Finansal zaman serilerinin tahmini, ekonomi, finans ve veri bilimi alanlarında önemli bir araştırma konusudur. Hisse senedi fiyatları; ekonomik koşullar, şirket performansı, piyasa beklentileri, yatırımcı psikolojisi ve küresel gelişmeler gibi çok sayıda faktörden etkilenmektedir. Bu nedenle fiyat hareketlerinin doğrusal yöntemlerle modellenmesi her zaman yeterli olmamaktadır. Özellikle finansal verilerde gürültü, dalgalanma ve doğrusal olmayan ilişkiler oldukça yaygındır.

Yapay sinir ağları, karmaşık örüntüleri öğrenebilme ve doğrusal olmayan ilişkileri modelleyebilme yetenekleri nedeniyle finansal tahmin problemlerinde sıkça kullanılmaktadır. Geleneksel istatistiksel yöntemler çoğu zaman belirli varsayımlara dayanırken, yapay sinir ağları veriden örüntü öğrenmeye odaklanır. Bu yönüyle özellikle zaman serisi tahmini, sınıflandırma, görüntü işleme, doğal dil işleme ve karar destek sistemleri gibi alanlarda güçlü sonuçlar verebilmektedir.

Bu çalışmanın amacı, THYAO hisse senedi kapanış fiyatlarını yapay sinir ağı tabanlı bir model ile tahmin etmektir. Veri setinin zamana bağlı yapısı nedeniyle klasik ileri beslemeli yapay sinir ağları yerine tekrarlayan sinir ağı ailesine ait LSTM mimarisi tercih edilmiştir. LSTM modeli, geçmiş gözlemleri hafıza mekanizması ile işleyebildiğinden zaman serilerinde avantajlı bir yapı sunmaktadır.

Çalışma kapsamında öncelikle yapay sinir ağlarının teorik temeli, literatürdeki gelişimi ve temel türleri açıklanmıştır. Daha sonra LSTM mimarisinin çalışma mantığı ele alınmış, ardından THYAO veri seti üzerinde veri ön işleme, özellik mühendisliği, model eğitimi ve performans değerlendirmesi gerçekleştirilmiştir.

2 Yapay Sinir Ağları

2.1 Yapay Sinir Ağlarının Temel Mantığı

Yapay sinir ağları, insan beynindeki biyolojik sinir hücrelerinden esinlenen hesaplama modelleridir. Bir yapay sinir ağı; giriş katmanı, bir veya daha fazla gizli katman ve çıkış katmanından oluşur. Her nöron kendisine gelen girdileri belirli ağırlıklarla çarpar, bunları toplar ve bir aktivasyon fonksiyonundan geçirerek çıktı üretir.

Bir yapay nöronun temel matematiksel gösterimi aşağıdaki gibidir:

$$z = \sum_{i=1}^n w_i x_i + b \quad (1)$$

$$y = f(z) \quad (2)$$

Burada x_i giriş değişkenlerini, w_i ağırlıkları, b bias terimini, f aktivasyon fonksiyonunu

ve y nöron çıktısını ifade etmektedir. Modelin öğrenme süreci, tahmin edilen çıktı ile gerçek çıktı arasındaki hatayı azaltacak şekilde ağırlıkların güncellenmesine dayanır.

2.2 Aktivasyon Fonksiyonları

Aktivasyon fonksiyonları, yapay sinir ağlarına doğrusal olmayan öğrenme yeteneği kazandırır. En yaygın aktivasyon fonksiyonları Sigmoid, Tanh ve ReLU fonksiyonlarıdır.

Tablo 1: Yapay Sinir Ağlarında Kullanılan Temel Aktivasyon Fonksiyonları

Fonksiyon	Matematiksel Gösterim	Kullanım Alanı
Sigmoid	$\sigma(x) = \frac{1}{1+e^{-x}}$	İkili sınıflandırma
Tanh	$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	RNN ve LSTM yapıları
ReLU	$f(x) = \max(0, x)$	Derin sinir ağları
Linear	$f(x) = x$	Regresyon problemleri

Bu çalışmada problem bir regresyon problemi olduğu için modelin son katmanında tek nöronlu doğrusal çıktı yapısı kullanılmıştır. Böylece model kapanış fiyatı gibi sürekli bir değişkeni tahmin edebilmektedir.

3 Yapay Sinir Ağları Literatür Taraması

Yapay sinir ağlarının temelleri McCulloch ve Pitts'in 1943 yılında önerdiği yapay nöron modeli ile atılmıştır. Bu çalışma, biyolojik nöronların matematiksel ve mantıksal bir modelle temsil edilebileceğini göstermesi açısından önemlidir [1]. Daha sonra Rosenblatt tarafından geliştirilen Perceptron modeli, öğrenen ilk yapay sinir ağı modellerinden biri olarak literatürde önemli bir yer edinmiştir [2].

1980'li yıllarda geri yayılım algoritmasının yaygınlaşması, çok katmanlı yapay sinir ağlarının eğitilmesini mümkün hale getirmiştir. Rumelhart, Hinton ve Williams tarafından tanıtılan geri yayılım yöntemi, ağıdaki ağırlıkların hata fonksiyonunu minimize edecek şekilde güncellenmesine olanak sağlamıştır [3]. Bu gelişme, yapay sinir ağlarının modern anlamda kullanımını hızlandırmıştır.

Derin öğrenme alanının gelişmesiyle birlikte çok katmanlı yapılar, büyük veri setleri ve gelişmiş optimizasyon algoritmaları sayesinde yapay sinir ağları çok daha karmaşık problemleri çözebilir hale gelmiştir. Goodfellow, Bengio ve Courville tarafından hazırlanan *Deep Learning* kitabı, modern derin öğrenme literatürünün temel kaynaklarından biri olarak kabul edilmektedir [5].

Zaman serisi ve sıralı veri problemlerinde ise tekrarlayan sinir ağları önemli bir rol oynamaktadır. Ancak klasik RNN modelleri uzun dönemli bağımlılıkları öğrenmede zorlanabilmektedir. Bu sorunu azaltmak için Hochreiter ve Schmidhuber tarafından LSTM

mimarisi geliştirilmiştir [4]. LSTM, kapı mekanizmaları sayesinde geçmiş bilgilerin hangi ölçüde saklanacağına veya unutulacağına karar verebilir. Bu nedenle finansal zaman serileri, doğal dil işleme ve ses verisi gibi sıralı veri problemlerinde yaygın şekilde kullanılmaktadır.

LSTM'e benzer şekilde GRU ve Transformer gibi farklı sıralı veri mimarileri de literatürde kullanılmaktadır. Ancak bu modellerin bazıları daha büyük veri setleri veya daha yüksek hesaplama gücü gerektirebildiğinden, bu çalışmada görece küçük ölçekli finansal zaman serisi için LSTM modeli daha uygun bir tercih olarak değerlendirilmiştir.

4 Yapay Sinir Ağı Türleri

Yapay sinir ağları, veri yapısına ve problem türüne göre farklı mimarilere ayrılmaktadır. Her mimari belirli veri tipleri ve problemler için daha uygundur.

Tablo 2: Temel Yapay Sinir Ağı Türleri ve Kullanım Alanları

Model Türü	Temel Özellik	Kullanım Alanı
MLP / ANN	İleri beslemeli klasik ağ yapısı	Regresyon ve sınıflandırma
CNN	Yerel örüntüleri ve filtreleri öğrenir	Görüntü işleme, sinyal analizi
RNN	Sıralı verilerde geçmiş bilgiyi kullanır	Zaman serisi, metin, ses
LSTM	Uzun dönemli bağımlılıkları öğrenir	Finansal tahmin, doğal dil işleme
GRU	LSTM'e göre daha sade ve hızlıdır	Küçük ve orta ölçekli zaman serileri
Autoencoder	Veriyi sıkıştırarak temsil öğrenir	Boyut indirgeme, anomali tespiti
Transformer	Dikkat mekanizması kullanır	Büyük ölçekli metin ve sıralı veri problemleri

Bu çalışmadaki veri seti günlük finansal zaman serisi yapısındadır. Gözlemler tarih sırasına göre birbirine bağlıdır. Bu nedenle model seçiminde zaman bağımlılığını öğrenebilen mimariler ön plana çıkmaktadır. MLP modeli kullanılabilse de, zaman sırasını doğrudan dikkate almadığı için bu problemde sınırlı kalabilir. CNN kısa dönemli örüntüleri yakalayabilir ancak uzun dönem bağımlılıkları öğrenmede LSTM kadar doğrudan bir mimari değildir. Transformer modelleri güçlü olmakla birlikte veri setinin büyüklüğü dikkate alındığında bu çalışma için gereğinden ağır bir yaklaşım olabilir. Bu nedenlerle LSTM modeli tercih edilmiştir.

5 LSTM Mimarisi

5.1 LSTM'nin Tercih Edilme Nedeni

LSTM, klasik RNN mimarisinin uzun dönemli bağımlılıkları öğrenmede yaşadığı kaybolan gradyan problemine çözüm olarak geliştirilmiştir. Klasik RNN yapılarında geçmiş bilgi her

zaman adımımda tekrar işlenir; ancak uzun dizilerde önceki bilgilerin etkisi giderek azalabilir. LSTM ise hücre durumu ve kapı mekanizmaları sayesinde hangi bilginin saklanacağını, hangisinin unutulacağını ve hangi bilginin çıktı olarak kullanılacağını öğrenebilir.

Bir LSTM hücresinde temel olarak üç kapı bulunmaktadır:

- **Forget Gate:** Geçmiş bilginin ne kadarının unutulacağını belirler.
- **Input Gate:** Yeni bilginin hücre durumuna ne kadar ekleneceğini belirler.
- **Output Gate:** Hücre durumundan hangi bilginin çıktı olarak verileceğini belirler.

Bu yapı sayesinde LSTM modelleri zaman serisi, finansal tahmin, konuşma tanıma ve doğal dil işleme gibi sıralı veri problemlerinde güçlü sonuçlar üretebilmektedir.

5.2 LSTM Matematiksel Yapısı

LSTM mimarisi Hochreiter ve Schmidhuber tarafından geliştirilmiş olup, aşağıda güncel literatürde yaygın kullanılan LSTM kapı denklemleri verilmiştir [4].

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (3)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (4)$$

$$\tilde{C}_t = \tanh(W_C[h_{t-1}, x_t] + b_C) \quad (5)$$

$$C_t = f_t C_{t-1} + i_t \tilde{C}_t \quad (6)$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (7)$$

$$h_t = o_t \tanh(C_t) \quad (8)$$

Burada f_t unutma kapısını, i_t giriş kapısını, o_t çıkış kapısını, C_t hücre durumunu, h_t gizli durumu ve x_t zaman t 'deki giriş vektörünü ifade etmektedir. Denklemlerin yanındaki numaralar kaynak numarası değil, LaTeX tarafından otomatik verilen denklem numaralarıdır.

6 Veri Seti


Bu çalışmada THYAO hisse senedine ait 2023–2025 dönemini kapsayan günlük finansal veriler kullanılmıştır. Veri setinde başlangıçta 749 gözlem bulunmaktadır. Veri temizleme

ve özellik mühendisliği işlemlerinden sonra lag ve hareketli ortalama değişkenleri nedeniyle ilk satırlarda oluşan eksik değerler temizlenmiş ve 730 gözlem kalmıştır.

Tablo 3: Veri Setinde Yer Alan Temel Değişkenler

Değişken	Açıklama
Date	İşlem tarihi
Open	Günlük açılış fiyatı
High	Gün içindeki en yüksek fiyat
Low	Gün içindeki en düşük fiyat
Close	Günlük kapanış fiyatı
Volume	Günlük işlem hacmi

Çalışmanın hedef değişkeni **Close** yani kapanış fiyatıdır. Modelin amacı geçmiş fiyat ve hacim bilgilerini kullanarak bir sonraki döneme ait kapanış fiyatını tahmin etmektir.



Şekil 1: THYAO Kapanış Fiyatı Zaman Serisi

Şekil 1 incelendiğinde THYAO kapanış fiyatının zaman içerisinde belirgin dalgalanmalar gösterdiği görülmektedir. Finansal serilerde fiyat hareketleri genellikle doğrusal olmayan ve gürültülü bir yapıdadır. Bu nedenle model seçiminde doğrusal olmayan ilişkileri öğrenebilen yapay sinir ağı mimarileri tercih edilmiştir.

7 Veri Ön İşleme ve Özellik Mühendisliği

7.1 Veri Temizleme

İlk aşamada veri setindeki tarih değişkeni tarih formatına dönüştürülmüş, fiyat ve hacim değişkenleri sayısal formata çevrilmiştir. Daha sonra veri tarih sırasına göre düzenlen-

miştir. Zaman serisi problemlerinde gözlemlerin sıralaması önemli olduğu için eğitim-test ayrımı yapılırken rastgele karıştırma işlemi uygulanmamıştır.

7.2 Lag Değişkenleri

Finansal zaman serilerinde geçmiş fiyatlar gelecekteki fiyat hareketleri hakkında bilgi taşıyabilir. Bu nedenle kapanış fiyatına ait gecikmeli değişkenler oluşturulmuştur:

- Close_lag_1
- Close_lag_3
- Close_lag_5
- Close_lag_10

Bu değişkenler modelin kısa ve orta vadeli geçmiş fiyat hareketlerini öğrenmesine yardımcı olmaktadır.

7.3 Hareketli Ortalamalar

Fiyat serilerindeki kısa vadeli dalgalanmaları yumuşatmak ve trend bilgisini modele aktarmak amacıyla hareketli ortalama değişkenleri oluşturulmuştur:

- MA_5
- MA_10
- MA_20

Hareketli ortalamalar, modelin fiyatın genel yönünü daha iyi algılamasına katkı sağlayan teknik göstergeler olarak kullanılmıştır.

7.4 Getiri Değişkeni

Günlük fiyat değişimini ölçmek amacıyla getiri değişkeni hesaplanmıştır:

$$Return_t = \frac{Close_t - Close_{t-1}}{Close_{t-1}} \quad (9)$$

Bu değişken fiyat seviyesinden ziyade günlük oransal değişimi temsil etmektedir.

7.5 Normalizasyon

LSTM modelleri ölçek farklılıklarına duyarlı olabilir. Bu nedenle modelde kullanılan tüm değişkenler MinMaxScaler yöntemi ile 0 ile 1 aralığına dönüştürülmüştür:

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (10)$$

Normalizasyon işlemi, modelin daha dengeli ve hızlı öğrenmesine katkı sağlamaktadır.


Tablo 4: Modelde Kullanılan Özellikler

Özellik Grubu	Değişkenler
Fiyat Değişkenleri	Open, High, Low, Close
Hacim Değişkeni	Volume
Lag Değişkenleri	Close_lag_1, Close_lag_3, Close_lag_5, Close_lag_10
Hareketli Ortalamalar	MA_5, MA_10, MA_20
Getiri Değişkeni	Return

8 Keşifsel Veri Analizi

8.1 Korelasyon Matrisi

Modelde kullanılan değişkenler arasındaki ilişkiyi incelemek amacıyla korelasyon matrisi oluşturulmuştur.



Şekil 2: Değişkenler Arası Korelasyon Matrisi

Şekil 2 incelendiğinde kapanış fiyatı ile açılış, en yüksek ve en düşük fiyat değişkenleri arasında çok güçlü pozitif ilişki olduğu görülmektedir. Ayrıca lag değişkenleri ve hareketli ortalamalar da kapanış fiyatı ile yüksek korelasyona sahiptir. Bu beklenen bir durumdur çünkü bu değişkenler doğrudan geçmiş fiyat bilgisinden türetilmiştir.

İşlem hacmi ile fiyat değişkenleri arasında daha zayıf ve negatif yönlü bir ilişki gözlenmiştir. Getiri değişkeni ise fiyat seviyeleriyle düşük korelasyon göstermektedir. Bu durum, getiri değişkeninin fiyat seviyesinden farklı bir bilgi taşıdığını göstermektedir.

Korelasyon matrisinde bazı değişkenler arasında yüksek korelasyon bulunması klasik doğrusal regresyon modellerinde çoklu doğrusal bağlantı sorununa neden olabilir. Ancak bu çalışmada katsayı yorumu yapılan doğrusal bir model değil, örüntü öğrenmeye dayalı LSTM modeli kullanılmıştır. Bu nedenle temel değerlendirme değişken katsayıları üzerinden değil, modelin test verisi üzerindeki tahmin performansı üzerinden yapılmıştır.

9 Model Tasarımı

9.1 Zaman Penceresi Yaklaşımı

LSTM modeli için veri seti 30 günlük zaman pencerelerine dönüştürülmüştür. Buna göre model, geçmiş 30 güne ait 13 değişkeni kullanarak bir sonraki gözleme ait kapanış fiyatını tahmin etmektedir.

Oluşturulan veri yapısı şu şekildedir:

Tablo 5: LSTM İçin Oluşturulan Veri Yapısı

Özellik	Değer
Ham gözlem sayısı	749
Özellik mühendisliği sonrası gözlem sayısı	730
Zaman penceresi uzunluğu	30 gün
Modelde kullanılan özellik sayısı	13
Toplam sequence sayısı	700
Eğitim örneği sayısı	560
Test örneği sayısı	140

9.2 Eğitim ve Test Ayrımı

Zaman serisi verilerinde gözlemlerin sırası bozulmamalıdır. Bu nedenle veri seti rastgele karıştırılmadan ayrılmıştır. İlk %80’lik bölüm eğitim seti, son %20’lik bölüm ise test seti olarak kullanılmıştır.

$$Train = 0.80 \times Data \quad (11)$$

$$Test = 0.20 \times Data \quad (12)$$

Bu ayırım sayesinde model geçmiş dönem verileriyle eğitilmiş ve daha sonraki dönem verileri üzerinde test edilmiştir. Böylece gerçek zaman serisi tahmin senaryosuna daha uygun bir değerlendirme yapılmıştır.

9.3 Model Mimarisi

Çalışmada iki katmanlı LSTM modeli kullanılmıştır. İlk LSTM katmanı 64 birimden, ikinci LSTM katmanı ise 32 birimden oluşmaktadır. Aşırı öğrenmeyi azaltmak amacıyla LSTM katmanları arasına Dropout katmanları eklenmiştir. Çıkış katmanında ise tek nöronlu Dense katmanı kullanılmıştır.

Tablo 6: Kullanılan LSTM Model Mimarisi

Katman	Çıkış Boyutu	Parametre Sayısı	Açıklama
LSTM	(30, 64)	19,968	İlk LSTM katmanı
Dropout	(30, 64)	0	Aşırı öğrenmeyi azaltma
LSTM	(32)	12,416	İkinci LSTM katmanı
Dropout	(32)	0	Aşırı öğrenmeyi azaltma
Dense	(1)	33	Kapanış fiyatı tahmini
Toplam	-	32,417	Eğitilebilir parametre sayısı


Modelde kayıp fonksiyonu olarak Ortalama Kare Hata (Mean Squared Error, MSE), optimizasyon algoritması olarak Adam kullanılmıştır. Adam algoritması, öğrenme oranını adaptif şekilde güncelleyebildiği için derin öğrenme modellerinde yaygın olarak tercih edilmektedir [6].

9.4 Early Stopping Kullanımı

Modelin gereksiz yere fazla epoch boyunca eğitilmesini ve aşırı öğrenmesini önlemek amacıyla Early Stopping yöntemi kullanılmıştır. Eğitim süreci için maksimum epoch sayısı 100 olarak belirlenmiş, ancak doğrulama kaybında iyileşme durduğu için eğitim 39. epoch civarında otomatik olarak sonlanmıştır. Bu durum hata değildir; aksine modelin doğrulama performansı iyileşmediğinde eğitimi durdurarak daha iyi genelleme yapılmasını sağlayan bir düzenleştirme yaklaşımıdır.

10 Model Eğitimi

Modelin eğitim sürecini değerlendirmek için eğitim kaybı ve doğrulama kaybı grafikleri incelenmiştir.



Şekil 3: LSTM Modeli Eğitim ve Doğrulama Kaybı

Şekil 3 incelendiğinde eğitim kaybının ilk epochlarda hızlı şekilde düştüğü görülmektedir. Bu durum modelin veri içerisindeki temel örüntüleri kısa sürede öğrendiğini göstermektedir. Doğrulama kaybının da düşük ve görece stabil seyretmesi modelde belirgin bir aşırı öğrenme problemi olmadığını göstermektedir. Eğitim kaybı ile doğrulama kaybı arasında çok büyük bir ayrışma olmaması, modelin test verisine genellenebilir bir yapı öğrendiğini desteklemektedir.

11 Model Performans Değerlendirmesi

Model performansı RMSE, MAE ve R^2 metrikleri ile değerlendirilmiştir.

11.1 RMSE

RMSE, tahmin hatalarının karelerinin ortalamasının kareköküdür. Büyük hataları daha fazla cezalandırır.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (13)$$

11.2 MAE

MAE, gerçek değerler ile tahmin değerleri arasındaki mutlak farkların ortalamasıdır.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (14)$$

11.3 R^2

R^2 , modelin bağımlı değişkendeki varyansın ne kadarını açıklayabildiğini gösterir.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (15)$$


Tablo 7: LSTM Model Performans Sonuçları

Metrik	Değer
RMSE	8.99
MAE	6.83
R^2	0.8463

Elde edilen sonuçlara göre modelin RMSE değeri 8.99, MAE değeri 6.83 ve R^2 değeri 0.8463 olarak hesaplanmıştır. R^2 değerinin 0.8463 olması, modelin test setindeki kapanış fiyatı değişkenliğinin yaklaşık %84.6'sını açıklayabildiğini göstermektedir. Finansal zaman serilerinin gürültülü ve dalgalı yapısı dikkate alındığında bu sonuç lisans düzeyinde bir yapay sinir ağı uygulaması için başarılı ve savunulabilir düzeydedir.

12 Tahmin Sonuçları

Modelin gerçek kapanış fiyatları ile tahmin edilen kapanış fiyatlarını ne ölçüde takip ettiğini görmek için Actual vs Predicted grafiği oluşturulmuştur.



Şekil 4: Gerçek ve Tahmin Edilen THYAO Kapanış Fiyatları

Şekil 4 incelendiğinde modelin genel fiyat trendini başarılı şekilde takip ettiği görülmektedir. Özellikle fiyatın yükseliş ve düşüş yönleri model tarafından büyük ölçüde yakalanmıştır. Bununla birlikte tahmin eğrisinin gerçek fiyat serisine göre daha yumuşak olduğu dikkat çekmektedir. Bu durum LSTM modellerinde sık görülen bir sonuçtur. Model, günlük finansal gürültüyü birebir yakalamaktan ziyade genel hareket yönünü ve trendi öğrenme eğilimindedir.

Grafikte ağustos ve eylül dönemindeki yükseliş hareketi, daha sonraki düşüş eğilimi ve yıl sonuna doğru gözlenen yatay seyir model tarafından genel olarak takip edilmiştir. Ancak ani fiyat sıçramaları ve sert düşüşlerde modelin daha temkinli tahminler ürettiği görülmektedir. Bu durum finansal zaman serilerindeki belirsizlik ve yüksek dalgalanma ile açıklanabilir.

13 Hata Analizi

Modelin tahmin hatalarını daha ayrıntılı incelemek amacıyla residual analiz yapılmıştır. Residual değerleri, gerçek kapanış fiyatı ile tahmin edilen kapanış fiyatı arasındaki farktır.

$$Residual_i = y_i - \hat{y}_i \quad (16)$$

13.1 Residual Error Grafiği




Şekil 5: Tahmin Hatalarının Gözlemlere Göre Dağılımı

Şekil 5 incelendiğinde tahmin hatalarının genel olarak sıfır etrafında dalgalandığı görülmektedir. Bazı dönemlerde pozitif ve negatif yönde daha büyük hatalar oluşmuştur. Bu durum özellikle fiyatlarda ani değişimlerin yaşandığı dönemlerde modelin kısa vadeli dalgalanmaları tam olarak yakalayamamasından kaynaklanabilir. Ancak hataların genel ola-

rak belirli bir yönde sürekli artış veya azalış göstermemesi modelin sistematik bir sapma üretmediğini göstermektedir.

13.2 Residual Distribution Grafiği



Şekil 6: Tahmin Hatalarının Dağılımı

Şekil 6 incelendiğinde hataların büyük ölçüde sıfır çevresinde yoğunlaştığı görülmektedir. Bu durum modelin genel olarak düşük hata ile tahmin yaptığını göstermektedir. Bununla birlikte histogramda bazı uç değerler yer almaktadır. Finansal zaman serilerinde beklenmedik haberler, piyasa duyarlılığı ve makroekonomik gelişmeler nedeniyle ani fiyat hareketleri oluşabileceğinden bu tür uç hatalar normal kabul edilebilir.

14 Bulguların Genel Değerlendirilmesi

Bu çalışmada THYAO kapanış fiyatı tahmini için LSTM tabanlı bir derin öğrenme modeli kurulmuştur. Model yalnızca temel fiyat ve hacim değişkenleriyle sınırlı bırakılmamış; lag değişkenleri, hareketli ortalamalar ve getiri değişkeni eklenerek özellik mühendisliği yapılmıştır. Bu sayede modelin geçmiş fiyat hareketlerini ve trend bilgisini daha iyi öğrenmesi amaçlanmıştır.

Model sonuçları genel olarak değerlendirildiğinde aşağıdaki bulgular elde edilmiştir:

- Model, test verisinde $R^2 = 0.8463$ değerine ulaşmıştır.
- RMSE değeri 8.99, MAE değeri ise 6.83 olarak hesaplanmıştır.

- Gerçek ve tahmin edilen fiyat grafiği, modelin genel trendi başarılı şekilde yakaladığını göstermektedir.
- Tahmin eğrisi gerçek fiyatlara göre daha yumuşaktır. Bu durum modelin ani günlük dalgalanmaları tam olarak yakalayamadığını, ancak genel yönü öğrendiğini göstermektedir.
- Residual analiz sonucunda hataların büyük ölçüde sıfır çevresinde toplandığı görülmüştür.
- Korelasyon matrisi, lag ve hareketli ortalama değişkenlerinin kapanış fiyatı ile güçlü ilişkiye sahip olduğunu göstermektedir.

Bu sonuçlar, LSTM modelinin finansal zaman serisi tahmini için uygun bir yöntem olduğunu göstermektedir. Bununla birlikte hisse senedi fiyatlarının yalnızca geçmiş fiyatlardan etkilenmediği unutulmamalıdır. Makroekonomik değişkenler, sektör haberleri, şirket finansalları, faiz oranları, döviz kuru ve piyasa beklentileri gibi dış faktörler de hisse fiyatları üzerinde önemli etkilere sahip olabilir.

15 Çalışmanın Sınırlılıkları

Bu çalışmanın bazı sınırlılıkları bulunmaktadır:

- Veri seti yalnızca THYAO hisse senedine ait geçmiş fiyat ve hacim bilgilerini içermektedir.
- Makroekonomik göstergeler, haber verileri veya şirket finansal tabloları modele dahil edilmemiştir.
- Veri seti yaklaşık üç yıllık günlük gözlemlerden oluşmaktadır. Daha uzun dönemli veri kullanımı modelin genelleme gücünü artırabilir.
- Model, günlük kapanış fiyatını tahmin etmektedir; yatırım kararı veya al-sat sinyali üretmek amacıyla tasarlanmamıştır.
- Finansal piyasalarda ani haber etkileri ve beklenmedik gelişmeler model tarafından doğrudan öngörülemez.

Bu sınırlılıklar dikkate alındığında model sonuçları finansal tahmin bağlamında dikkatli yorumlanmalıdır.

16 Gelecek Çalışmalar

Model performansını artırmak için ileride farklı geliştirmeler yapılabilir:

- RSI, MACD, Bollinger Bandı gibi teknik analiz göstergeleri eklenebilir.
- Döviz kuru, faiz oranı, BIST100 endeksi ve petrol fiyatı gibi dış değişkenler modele dahil edilebilir.
- LSTM modeli GRU, Bidirectional LSTM ve CNN-LSTM gibi farklı mimarilerle karşılaştırılabilir.
- Farklı zaman pencereleri denenerek 10, 20, 30 ve 60 günlük geçmiş verinin performans etkisi analiz edilebilir.
- Hiperparametre optimizasyonu ile LSTM birim sayısı, dropout oranı, batch size ve learning rate değerleri iyileştirilebilir.

Bu geliştirmeler modelin tahmin gücünü artırabilir ve daha kapsamlı bir finansal tahmin sistemi kurulmasına katkı sağlayabilir.

17 Sonuç

Bu çalışmada yapay sinir ağlarının teorik yapısı, literatürdeki gelişimi ve temel türleri incelenmiş; ardından THYAO hisse senedi kapanış fiyatı tahmini için LSTM tabanlı bir model uygulanmıştır. Veri seti zaman serisi yapısına uygun şekilde hazırlanmış, lag değişkenleri, hareketli ortalamalar ve getiri değişkeni oluşturularak modelin geçmiş fiyat bilgilerini daha etkin kullanması sağlanmıştır.

Kurulan LSTM modeli test verisinde $R^2 = 0.8463$ sonucuna ulaşmıştır. Bu değer, modelin kapanış fiyatındaki değişimin yaklaşık %84.6'sını açıklayabildiğini göstermektedir. Ayrıca RMSE ve MAE değerleri modelin tahmin hatalarının kabul edilebilir düzeyde olduğunu göstermektedir.

Gerçek ve tahmin edilen fiyat grafikleri incelendiğinde modelin genel trendi başarılı şekilde takip ettiği, ancak günlük ani dalgalanmaları daha yumuşak tahmin ettiği görülmüştür. Bu durum finansal zaman serilerinin gürültülü ve belirsiz yapısıyla uyumludur.

Sonuç olarak LSTM modeli, THYAO kapanış fiyatı tahmini için uygun ve başarılı bir yapay sinir ağı yaklaşımı sunmuştur. Çalışma, yapay sinir ağlarının finansal zaman serisi tahmininde nasıl uygulanabileceğini göstermesi açısından anlamlı bir örnek oluşturmaktadır.

Kaynaklar

- [1] McCulloch, W. S., & Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The Bulletin of Mathematical Biophysics*, 5, 115–133.
- [2] Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408.
- [3] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323, 533–536.
- [4] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [5] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [6] Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.